

DÉTECTION DU CANCER DU SEIN PAR APPRENTISSAGE STATISTIQUE





1.INTRODUCTION & PROBLEMATIQUE



1. INTRODUCTION:

La détection précoce joue un rôle essentiel dans l'amélioration des chances de guérison et dans la réduction du taux de mortalité.


Actuellement, le dépistage repose principalement sur des examens d'imagerie médicale tels que :

- La mammographie
- L'échographie mammaire
- L'IRM mammaire

Ces méthodes ont permis d'améliorer considérablement le diagnostic précoce, mais elles présentent certaines limites.

PROBLEMATIQUE:

Peut-on utiliser les techniques de Machine Learning pour détecter efficacement le cancer du sein à partir de biomarqueurs sanguins et de données cliniques ?





2. EDA (EXPLORATORY DATA ANALYSIS)



2. EDA (EXPLORATORY DATA ANALYSIS)


DESCRIPTION DES DONNÉES

- Nombre d'observations : 116
- Nombre de variables :
9 biomarqueurs + cible
- Répartition des classes :
- 52 saines
- 64 cancéreuses
- Aucune valeur manquante



HEATMAP DES CORRÉLATIONS:

Matrice de corrélation des biomarqueurs
(Coimbra Breast Cancer Dataset)




- **Interpretations :**

La corrélation la plus forte est entre HOMA et Insulin (0,93), ce qui est attendu puisque HOMA est calculé directement à partir de l'insuline et du glucose. On observe également une corrélation notable entre HOMA et Glucose (0,70) et entre Insulin et Glucose (0,50).


Leptin et BMI sont modérément corrélées (0,57), ce qui est cohérent biologiquement : la leptine est une hormone sécrétée par le tissu adipeux, donc liée à la corpulence. En revanche, la plupart des autres paires de variables ont des corrélations faibles (proches de 0), ce qui indique une relative indépendance entre elles.

Implication pour la modélisation : la forte colinéarité entre Insulin et HOMA peut poser problème aux modèles linéaires non régularisés. C'est une des justifications de l'utilisation de Ridge et Lasso dans notre étude.



BOXPLOTS DES BIOMARQUEURS

Distribution des biomarqueurs clés selon la classe
(Sain vs Cancer du sein)



• Interpretations :

Les boxplots comparent les distributions de six variables entre les patientes Saines et Cancer.

Variables avec différences visibles :

- Glucose : médiane plus élevée dans la classe Cancer, avec des valeurs extrêmes très élevées.
- Insulin et HOMA : distributions plus étalées dans la classe Cancer, avec davantage de valeurs atypiques (outliers) élevés.
- Resistin : tendance similaire, avec quelques valeurs très élevées chez les patientes cancéreuses.

Variables avec peu de différences :

- Leptin et BMI : les distributions des deux classes se chevauchent largement, ce qui les rend moins discriminantes à elles seules.

Conclusion générale : aucun biomarqueur ne sépare parfaitement les deux classes. La distinction repose donc sur la combinaison de plusieurs variables, ce qui justifie pleinement le recours à des modèles de classification multivariée.



PRÉTRAITEMENT

- Encodage de la cible
- Split 80/20
- Standardisation

POURQUOI?

- Éviter le Data Leakage
- Améliorer les performances





3.MODÈLES

PIPELINE DES MODELES



<u>Modèle</u>	<u>Objectif</u>
Régression Logistique	Baseline interprétable
Naive Bayes	Modèle probabiliste
Ridge	Gestion de la colinéarité
Lasso	Sélection de variables
KNN	Similarité locale
MLP	Réseau de neurones

VALIDATION CROISÉE

```
cv = RepeatedStratifiedKFold(n_splits=5, n_repeats=5, random_state=42)  
scoring = "balanced_accuracy"
```

La validation croisée utilisée est une validation stratifiée répétée : 5 folds répétés 5 fois. La métrique d'optimisation est la `balanced_accuracy`, car elle tient compte à la fois de la sensibilité et de la spécificité.

Chaque modèle possède une recherche par `GridSearchCV` et le score moyen de validation croisée CV

RÉGRESSION LOGISTIQUE






FIGURE 3 – Régression Logistique : coefficients standardisés

```
logreg_pipeline = Pipeline([
    ("scaler", StandardScaler()),
    ("model", LogisticRegression(penalty="l2", solver="lbfgs",
                                max_iter=2000, class_weight="balanced"))
])
logreg_grid = {"model__C": [0.01, 0.1, 1, 10, 100]}
logreg_search = GridSearchCV(logreg_pipeline, logreg_grid, cv=cv,
                              scoring="balanced_accuracy")
logreg_search.fit(X_train, y_train)
```

- **Interpretations :**
 - Glucose et Resistin ont des coefficients positifs importants
 - Leptin, BMI et Age ont des coefficients négatifs.
 - Associations apprises par le modèle, et non comme des causalités médicales.
 - Le meilleur score CV obtenu est 0,7604.




CLASSIF NAIVE BAYES



```
logreg_pipeline = Pipeline([
    ("scaler", StandardScaler()),
    ("model", LogisticRegression(penalty="l2", solver="lbfgs",
                                max_iter=2000, class_weight="balanced"))
])
logreg_grid = {"model__C": [0.01, 0.1, 1, 10, 100]}
logreg_search = GridSearchCV(logreg_pipeline, logreg_grid, cv=cv,
                              scoring="balanced_accuracy")
logreg_search.fit(X_train, y_train)
```

- **Interpretations :**
 - Glucose, HOMA, Insulin et Resistin sont plus élevés en moyenne dans la classe Cancer.
 - Malgré une bonne AUC sur le test, Naive Bayes présente une sensibilité faible.
 - Le meilleur score CV obtenu est 0,6517.



RIDGE





FIGURE 5 – RidgeClassifier : coefficients standardisés


```
ridge_pipeline = Pipeline([
    ("scaler", StandardScaler()),
    ("model", RidgeClassifier(class_weight="balanced"))
])
ridge_grid = {"model__alpha": np.logspace(-3, 3, 7)}
ridge_search = GridSearchCV(ridge_pipeline, ridge_grid, cv=cv,
                             scoring="balanced_accuracy")
ridge_search.fit(X_train, y_train)
```

- **Interpretations :**
 - Ridge met surtout en avant Insulin, Glucose et HOMA.
 - La régularisation L2 limite les coefficients extrêmes, ce qui rend le modèle plus stable face à la colinéarité.
 - Le meilleur score CV obtenu est 0,7436 .




LASSO

Lasso — coefficients standardisés et sélection de variables




```
lasso_pipeline = Pipeline([
    ("scaler", StandardScaler()),
    ("model", LogisticRegression( penalty="l1", solver="liblinear", max_iter=3000,
        class_weight="balanced", random_state=RANDOM_STATE
    ))
])
lasso_params = {
    "model__C": [0.001, 0.005, 0.01, 0.05, 0.1, 0.5, 1, 5, 10, 50, 100]
}
lasso_grid = GridSearchCV( estimator=lasso_pipeline, param_grid=lasso_params,
    scoring="balanced_accuracy", cv=cv, n_jobs=-1, refit=True
)
lasso_grid.fit(X_train, y_train)
```

- **Interpretations :**
 - Lasso applique une régularisation L1.
 - Cette régularisation permet une sélection automatique des variables.
 - Glucose, Resistin et Insulin sont les variables positives les plus importantes.
 - Leptin, BMI et Age ont des coefficients négatifs.
 - HOMA, Adiponectin et MCP.1 sont éliminées, car leurs coefficients deviennent nuls.
 - Le meilleur score CV obtenu est 0,7546.




K-NN — meilleur score CV selon le nombre de voisins




```
knn_pipeline = Pipeline([
    ("scaler", StandardScaler()), ("model", KNeighborsClassifier())
])
knn_params = {
    "model_n_neighbors": [3, 5, 7, 9, 11, 13, 15],
    "model_weights": ["uniform", "distance"],
    "model_metric": ["euclidean", "manhattan"]
}
knn_grid = GridSearchCV(estimator=knn_pipeline, param_grid=knn_params,
    scoring="balanced_accuracy", cv=cv, n_jobs=-1, refit=True)
knn_grid.fit(X_train, y_train)
```

- **Interpretations :**
 - K-NN se base sur les patients les plus proches.
 - Le meilleur score CV est obtenu avec $k = 11$.
 - Les performances sont stables pour plusieurs valeurs de k .
 - Le modèle offre le meilleur compromis médical.
 - Il détecte mieux les cas de cancer et réduit les faux négatifs.




MLP — évolution de la fonction de perte



```
mlp_pipeline = Pipeline([
    ("scaler", StandardScaler()), ("model", MLPClassifier(activation="relu",
        solver="adam", max_iter=1500, early_stopping=True, validation_fraction=0.15,
        n_iter_no_change=30, random_state=RANDOM_STATE
    ))
])
mlp_params = {
    "model__hidden_layer_sizes": [(16,), (32,), (32, 16)],
    "model__alpha": [0.0001, 0.001, 0.01],
    "model__learning_rate_init": [0.001, 0.01]
}
mlp_grid = GridSearchCV(
    estimator=mlp_pipeline, param_grid=mlp_params, scoring="balanced_accuracy",
    cv=cv, n_jobs=-1, refit=True
)
mlp_grid.fit(X_train, y_train)
```

- **Interpretations :**







- Le MLP apprend des relations non linéaires.
- La perte diminue régulièrement pendant l'entraînement.
- Cela indique une bonne convergence du modèle.
- Adam ajuste les poids pour minimiser l'erreur.
- Cependant, le MLP reste moins performant que K-NN.
- Il rate plus de cas de cancer dans le test.






4.ÉVALUATION

Matrices de confusion — comparaison des 6 modèles



COURBE ROC



METRIQUE UTILISÉ

Métrique	Définition	Formule	Importance
Accuracy	Proportion totale de prédictions correctes.	$(TP + TN)/(TP + TN + FP + FN)$	Mesure la performance globale du modèle.
Spécificité	Proportion de patientes saines correctement reconnues parmi toutes les vraies patientes saines.	$(TN)/(TP + FP)$	Permet d'éviter de classer trop de patientes saines comme malades.
Recall / Sensibilité	Proportion de cancers correctement détectés parmi tous les vrais cancers.	$(TP)/(TP + FN)$	Très importante pour détecter le maximum de cancers.
F1-score	Moyenne harmonique entre Precision et Recall.	$2 * (Precision * Recall)/(Precision + Recall)$	Donne un équilibre entre Precision et Recall.
AUC-ROC	Aire sous la courbe ROC. Elle mesure la capacité du modèle à séparer les deux classes.	Aire sous la courbe ROC	Évalue la qualité globale de séparation entre Sain et Cancer.

UNE MÉTRIQUE PERSONNALISÉE CRÉÉE POUR LE CONTEXTE MÉDICAL:

SCORE MÉDICAL PONDÉRÉ = 0.40*RECALL+0.30*SP2CIFICIT2+0.20*F1_SCORE+0.10*AUC_ROC

RÉSULTATS DES MODÈLES

<u>Modèle</u>	<u>Accuracy</u>	<u>Recall</u>	<u>Spécificité</u>	<u>F1-score</u>	<u>AUC-ROC</u>	<u>FN</u>	<u>FP</u>	<u>Score médical</u>	<u>Interprétation</u>
<u>K-NN</u>	0.7917	0.7692	0.8182	0.8000	0.7937	3	2	0.7925	Meilleur compromis global
<u>Régression Logistique</u>	0.7083	0.6154	0.8182	0.6957	0.7762	5	2	0.7084	Bon équilibre, mais rate 5 cancers
<u>MLP</u>	0.7083	0.6154	0.8182	0.6957	0.7692	5	2	0.7077	Correct, mais pas meilleur que K-NN
<u>Lasso</u>	0.7083	0.6154	0.8182	0.6957	0.7622	5	2	0.7070	Résultat proche de la régression logistique
<u>Naive Bayes</u>	0.6667	0.4615	0.9091	0.6000	0.8671	7	1	0.6641	Bonne AUC, mais trop de cancers ratés
<u>Ridge</u>	0.6667	0.5385	0.8182	0.6364	0.7133	6	2	0.6594	Performance moyenne




KNN → meilleur compromis global




4.COMPARAISON


COMPARAISON DES MODÈLES



CLASSEMENT DES MODÈLES



INTERPRÉTATION GLOBALE DES VARIABLES





5.CONCLUSION ET PRESPECTIVES



CONCLUSION & PERSPECTIVES

Conclusion

- Les biomarqueurs sanguins permettent une détection prometteuse.
- Glucose, Resistin, Insulin et HOMA sont les variables les plus importantes.
- Les modèles de ML peuvent assister le diagnostic.

Perspectives

- optimisation du seuil de décision.
- SVM /XGBoost / LightGBM ou CatBoost.
- Validation sur d'autres hôpitaux
- Plus de données



MERCI

